

Redes neuronales convolucionales ligeras para el diagnóstico de enfermedades en hojas de papa con hardware de consumo: un estudio de entrenamiento desde cero frente al aprendizaje por transferencia con interpretabilidad mediante Grad-CAM

Niels Pacheco¹

¹Programa de Maestría en Inteligencia Artificial, MIA-07 Redes Neuronales y Aprendizaje Profundo (Sección C). nielspacheco1997@gmail.com

Junio de 2026

Resumen

Las enfermedades foliares como el tizón temprano (*Alternaria solani*) y el tizón tardío (*Phytophthora infestans*) amenazan a la papa (*Solanum tuberosum*), el cultivo básico domesticado en los Andes peruanos y el tercer alimento más importante del mundo. Las redes neuronales convolucionales (CNN) pueden reconocer estas enfermedades a partir de fotografías de hojas, pero la mayoría de los sistemas reportados dependen de grandes redes preentrenadas y de unidades de procesamiento gráfico (GPU) que no están al alcance de los pequeños agricultores que más se beneficiarían. Nos preguntamos si una CNN compacta entrenada *desde cero* en hardware de consumo (una laptop con CPU/Apple Silicon, sin GPU) puede rivalizar con los modelos de aprendizaje por transferencia preentrenados en ImageNet para la clasificación de hojas de papa en tres clases (sana, tizón temprano, tizón tardío). Sobre el subconjunto de papa de PlantVillage (2152 imágenes) comparamos una CNN propia de 328,587 parámetros frente a MobileNetV2, ResNet-18 y EfficientNet-B0 con redes base de ImageNet congeladas y cabezales ajustados, evaluando cada modelo sobre 3 semillas aleatorias, reportando desviaciones estándar entre semillas e intervalos de confianza no paramétricos por *bootstrap*, con pruebas de significancia de McNemar y análisis de calibración. Sorprendentemente, la CNN propia entrenada desde cero alcanza 96.7% de F1 macro, *superando* al mejor modelo por transferencia (EfficientNet-B0, 91.7%); las pruebas pareadas de McNemar confirman que supera significativamente a los tres modelos por transferencia de red base congelada ($p < 0.05$) usando del orden de 7–34× menos parámetros. El resultado indica que, bajo un presupuesto de cómputo igualmente bajo, aprender de extremo a extremo características compactas y específicas del dominio supera a reutilizar características congeladas de ImageNet. No obstante, los mapas de saliencia de Grad-CAM indican que todos los modelos atienden en parte al fondo de la imagen y no a las lesiones de la hoja, en concordancia cualitativa con el bien documentado sesgo de fondo de PlantVillage, lo que matiza las exactitudes optimistas. Publicamos una canalización totalmente reproducible—entorno fijado, semillas fijas, experimentos dirigidos por configuración y una construcción de este manuscrito con un solo comando—para apoyar una investigación de enfermedades vegetales honesta y accesible en hardware.

1 Introducción

La papa es el tercer cultivo alimentario más importante para el consumo humano en el mundo y fue domesticada por primera vez hace más de siete mil años en las tierras altas de lo que hoy es Perú y Bolivia [1]. Su productividad está crónicamente amenazada por enfermedades foliares. El tizón tardío, causado por el oomiceto *Phytophthora infestans*, desencadenó la hambruna irlandesa del siglo XIX y sigue siendo hoy la enfermedad más destructiva de la papa, capaz de arrasar un campo entero en cuestión de días [2]. El tizón temprano, causado por el hongo *Alternaria solani*, también está muy extendido. La identificación temprana y precisa de estas enfermedades a partir de los síntomas foliares permite una intervención oportuna, pero el diagnóstico experto es escaso en las comunidades rurales andinas donde se concentra el cultivo de la papa.

El aprendizaje profundo ofrece una vía hacia un diagnóstico democratizado. Desde que se demostró que las CNN pueden clasificar imágenes de enfermedades vegetales con alta exactitud [3, 4], una amplia literatura ha aplicado redes preentrenadas cada vez más grandes al problema. Sin embargo, dos preocupaciones prácticas están poco examinadas. Primero, la mayoría de los sistemas asume acceso a GPU y a grandes redes preentrenadas, un supuesto reñido con los entornos de recursos limitados donde la tecnología es más necesaria. Segundo, las exactitudes destacadas del campo se reportan con frecuencia sin intervalos de confianza, sin

análisis de calibración y sin verificación alguna de que el modelo atienda a la enfermedad y no a correlaciones espurias del conjunto de datos.

Este trabajo aborda ambas preocupaciones mediante un estudio enfocado y reproducible. Planteamos una sola pregunta: *¿qué tan cerca puede llegar una CNN pequeña entrenada desde cero en una laptop sin GPU al aprendizaje por transferencia preentrenado en ImageNet para la clasificación de enfermedades en hojas de papa?* Nuestras contribuciones son:

1. Una CNN propia compacta (328,587 parámetros) que se entrena de extremo a extremo en hardware CPU o Apple Silicon, comparada directamente con modelos de aprendizaje por transferencia (MobileNetV2, ResNet-18 y EfficientNet-B0 con redes base de ImageNet congeladas y cabezales de clasificación ajustados).
2. Una evaluación estadísticamente rigurosa—corridas con múltiples semillas y desviaciones estándar entre semillas, intervalos de confianza por *bootstrap* al 95 % por corrida, y la prueba pareada de McNemar sobre un conjunto de prueba compartido [5]—en lugar de un único número de exactitud.
3. Un análisis de calibración (error de calibración esperado y diagramas de fiabilidad) [6], rara vez reportado en el trabajo de enfermedades vegetales.
4. Un estudio de interpretabilidad con Grad-CAM [7] que sondea el documentado sesgo de fondo de PlantVillage [8], con una discusión honesta de la brecha entre el rendimiento de laboratorio y el de campo.
5. Una publicación de código abierto totalmente reproducible (dependencias fijadas, semillas fijas, corridas dirigidas por configuración, generación automatizada de figuras y del manuscrito).

2 Trabajo relacionado

Clasificación de enfermedades vegetales. Mohanty et al. [3] entrenaron AlexNet y GoogLeNet sobre el conjunto PlantVillage y reportaron exactitudes superiores al 99 % bajo evaluación dentro del mismo conjunto, estableciendo el punto de referencia que sigue gran parte del trabajo posterior. Ferentinos [4] extendió el enfoque a docenas de combinaciones cultivo-enfermedad. De manera crucial, Barbedo [9] mostró que tales exactitudes se degradan abruptamente cuando los modelos se evalúan con imágenes recolectadas en condiciones distintas, atribuyendo la caída a la limitada variedad del conjunto de datos y a las señales del fondo, y Noyan [8] demostró explícitamente que un clasificador puede recuperar las etiquetas de PlantVillage a partir *únicamente del fondo*. Tomamos en serio esta crítica y la ponemos a prueba directamente con Grad-CAM.

Arquitecturas eficientes y de transferencia. Las conexiones residuales permitieron entrenar redes muy profundas [10]; MobileNetV2 [11] y EfficientNet [12] optimizaron después el compromiso entre exactitud y número de parámetros para el despliegue con recursos limitados. El aprendizaje por transferencia desde ImageNet [13] es la receta por defecto para conjuntos de datos pequeños. Nuestro estudio usa estas redes base como líneas base fuertes, pero se pregunta qué es recuperable *sin* sus pesos preentrenados.

Interpretabilidad. Grad-CAM [7] produce mapas de saliencia discriminativos por clase ponderando las activaciones convolucionales con los gradientes del puntaje de clase, y se ha convertido en una herramienta estándar para verificar que la evidencia de un modelo sea plausible. La usamos no para confirmar el éxito, sino para exponer un modo de fallo.

3 Métodos

3.1 Conjunto de datos

Usamos el subconjunto de papa de PlantVillage [14], que comprende 2152 imágenes RGB de hojas en tres clases—sana, tizón temprano y tizón tardío—fotografiadas en condiciones controladas de laboratorio (Fig. 1). Las clases están desbalanceadas (la clase sana es la más pequeña). Particionamos los datos una sola vez en conjuntos de entrenamiento, validación y prueba de aproximadamente 70/15/15 %, estratificados por clase, usando una semilla de partición fija de modo que *todos* los modelos se entrenan y evalúan en particiones idénticas; esto da 1506 imágenes de entrenamiento, 323 de validación y 323 de prueba. Mantener la partición fija es lo que hace válida la prueba pareada de McNemar entre modelos.

PlantVillage potato leaf classes



Figura 1: Imágenes representativas de hojas de papa de cada clase, tomadas del conjunto de prueba reservado. Las imágenes de PlantVillage se capturan sobre fondos bastante uniformes—una propiedad que, como mostramos, los modelos pueden explotar.

3.2 Preprocesamiento y aumentación

Las imágenes se redimensionan y recortan al centro a 128×128 píxeles y se normalizan con las estadísticas de canal de ImageNet (aplicadas de manera uniforme a todos los modelos para que sólo difieran la arquitectura y los pesos). Durante el entrenamiento aplicamos recorte aleatorio redimensionado, volteo horizontal, pequeñas rotaciones y variación de color (*color jitter*), con una intensidad de aumentación seleccionada por la búsqueda de hiperparámetros.

3.3 Modelos

La **CNN propia** es una red de cuatro bloques construida desde cero: cada bloque aplica dos convoluciones de 3×3 con normalización por lotes [15] y activaciones ReLU seguidas de *max pooling*, con anchos de canal que crecen y luego se estabilizan para mantener el modelo compacto (328,587 parámetros). Una capa de *global average pooling* alimenta a un clasificador lineal regularizado con *dropout* [16]. Las tres **líneas base por transferencia**—MobileNetV2 [11], ResNet-18 [10] y EfficientNet-B0 [12]—se inicializan con pesos preentrenados en ImageNet; congelamos cada red base y entrenamos sólo un nuevo cabezal de clasificación, la receta estándar de transferencia con pocos datos.

3.4 Entrenamiento

Todos los modelos se entrenan con el optimizador AdamW [17, 18], una planificación coseno de la tasa de aprendizaje, entropía cruzada ponderada por clase con suavizado de etiquetas [19] para contrarrestar el desbalance de clases, y parada temprana sobre el F1 macro de validación. Los hiperparámetros de la CNN propia se seleccionaron mediante una búsqueda aleatoria con semilla de 10 configuraciones sobre tasa de aprendizaje, decaimiento de pesos, ancho de la red, *dropout* e intensidad de aumentación, optimizando únicamente el F1 macro de validación (el conjunto de prueba nunca se consulta durante la selección del modelo). La búsqueda seleccionó una tasa de aprendizaje de 0.001, decaimiento de pesos $1e - 05$, ancho 24, *dropout* 0.3 e intensidad de aumentación 0.5. Todos los experimentos corren en una laptop Apple Silicon usando el *backend* Metal (MPS) de PyTorch [20]; no se usa GPU.

3.5 Evaluación y estadística

Para cada modelo reportamos exactitud y F1 promediado por macro (robusto al desbalance de clases), cada uno como media y desviación estándar sobre 3 semillas aleatorias (Cuadro 1, Fig. 2). Para cuantificar la incertidumbre de muestreo dentro del conjunto de prueba, además calculamos intervalos de confianza no paramétricos al 95 % mediante remuestreo *bootstrap* del conjunto de prueba para cada corrida; estos se publican con las métricas por corrida y los intervalos del mejor modelo se citan en los Resultados. Comparamos los modelos por pares sobre su conjunto de prueba compartido con la prueba de McNemar [5], usando la forma binomial exacta cuando el número de predicciones discordantes es pequeño. Evaluamos la calibración con el error de calibración esperado (ECE) y diagramas de fiabilidad [6]. Por último, calculamos mapas de saliencia de Grad-CAM [7] para inspeccionar qué regiones de la imagen impulsan cada predicción.

Cuadro 1: Rendimiento en el conjunto de prueba sobre la partición reservada de hojas de papa ($n = 323$ imágenes), reportado como media $\pm$ desviación estándar sobre 3 semillas aleatorias. La exactitud y el F1 macro están en porcentaje; ECE es el error de calibración esperado (menor es mejor). Params = parámetros totales.

Modelo	Params	Exactitud (%)	F1 macro (%)	ECE
CNN propia (desde cero)	328,587	97.3 ± 2.3	96.7 ± 2.1	0.123
MobileNetV2	2,227,715	94.9 ± 0.8	91.6 ± 1.2	0.134
ResNet-18	11,178,051	91.7 ± 1.5	86.5 ± 2.1	0.171
EfficientNet-B0	4,011,391	94.9 ± 0.5	91.7 ± 1.4	0.157

Cuadro 2: Métricas de prueba por clase para el mejor modelo (CNN propia (desde cero), semilla representativa). El soporte es el número de imágenes de prueba por clase.

Clase	Precisión	Sensibilidad	F1	Soporte
Sana	0.917	0.957	0.936	23
Tizón temprano	0.980	1.000	0.990	150
Tizón tardío	0.993	0.967	0.980	150

4 Resultados

4.1 Desempeño de clasificación

El Cuadro 1 resume el desempeño de prueba. Los cuatro modelos clasifican las tres condiciones de la papa con exactitud, reflejando la naturaleza relativamente limpia y controlada en laboratorio de PlantVillage. El resultado destacado, sin embargo, es que la CNN propia entrenada desde cero no sólo es competitiva sino la *mejor*: con apenas 328,587 parámetros alcanza 96.7 % de F1 macro, por delante del mejor modelo por transferencia (EfficientNet-B0, 91.7 %) y muy por delante de ResNet-18 (Fig. 2). Las pruebas pareadas de McNemar sobre el conjunto de prueba compartido (semilla 0) encuentran que la CNN propia es significativamente mejor que cada línea base de red base congelada ($p = 0.0169$ frente a EfficientNet-B0, y menor frente a las demás; véase `summary.json` en el repositorio). Un *bootstrap* no paramétrico sobre ese conjunto de prueba sitúa el F1 macro de la CNN propia en [93.6, 99.5] % (IC al 95 %) y su exactitud en [96.6, 99.4] %. La prueba de significancia se calcula sobre las predicciones de una sola semilla, pero el orden no es específico de la semilla: en las tres semillas, el F1 macro medio de la CNN propia (96.7 %) supera la media de cada línea base. La interpretación es que, cuando sólo puede entrenarse un pequeño cabezal de clasificación sobre una red base de ImageNet congelada, esas redes base aportan características genéricas mal ajustadas a la patología foliar, mientras que la CNN compacta—entrenada de extremo a extremo—aprende características específicas de la tarea. Las curvas de F1 macro de validación (Fig. 3) muestran que todos los modelos alcanzan una meseta alta dentro del presupuesto de entrenamiento.

4.2 Estructura de confusión

Las matrices de confusión (Fig. 4) son informativas más allá de la exactitud destacada. Para el mejor modelo (CNN propia) los pocos errores son predominantemente confusiones enfermedad-versus-enfermedad—un patrón operativamente benigno, ya que ambos estados enfermos ameritan intervención. Los modelos por transferencia congelada, más débiles, en cambio clasifican erróneamente además un número no trivial de hojas con *tizón tardío* como *sanas* (por ejemplo, 10–12 de 150 para MobileNetV2 y ResNet-18): un modo de falso negativo mucho más preocupante, porque le diría a un agricultor que una planta infectada está sana. Esta asimetría—el modelo entrenado desde cero no sólo puntúa más alto sino que falla de forma más segura—refuerza el argumento a favor del modelo compacto de extremo a extremo. La clase minoritaria sana se reconoce de manera fiable en todos los modelos, lo que indica que la ponderación de clases contrarresta el desbalance.

4.3 Calibración

Más allá de la exactitud, un diagnóstico desplegable debería reportar confianzas fiables. La Fig. 5 muestra diagramas de fiabilidad y valores de ECE (para una semilla representativa; el Cuadro 1 reporta el ECE promediado entre semillas). Todos los modelos están imperfectamente calibrados, con un ECE promediado entre semillas que va de 0.123 (CNN propia, la mejor calibrada) a cerca de 0.17 (ResNet-18). Los diagramas indican que la mala calibración se debe principalmente a los compartimentos de confianza media, donde la exactitud empírica y la confianza predicha divergen, más que a un exceso de confianza uniforme. Esta es una limitación honesta: si bien la CNN propia es a la vez la más exacta y la mejor calibrada de las cuatro,




Figura 2: Exactitud y F1 macro de prueba (media $\pm$ desviación estándar sobre 3 semillas) para los cuatro modelos.




Figura 3: F1 macro de validación a lo largo de las épocas de entrenamiento (semilla representativa). Las redes base preentrenadas convergen rápido; la CNN entrenada desde cero converge más lentamente a un nivel similar.

ninguna está calibrada lo bastante bien como para tomar sus confianzas crudas al pie de la letra, y un sistema desplegado se beneficiaría de una calibración posterior (por ejemplo, escalado por temperatura) antes de usar la confianza para derivar los casos inciertos a un experto humano.

4.4 ¿Dónde miran los modelos?

Los mapas de saliencia de Grad-CAM (Fig. 6) aportan la observación cualitativa más importante del estudio. Aunque los modelos sí ponen atención en las lesiones visibles para las clases de enfermedad, también asignan una saliencia sustancial a los bordes de la hoja y al fondo uniforme. Mostramos ejemplos individuales representativos por clase, de modo que esto es ilustrativo y no una medición cuantitativa de atribución; no obstante, es visualmente consistente con el sesgo de fondo que Noyan [8] y Barbedo [9] documentaron, lo que sugiere que parte de la aparente habilidad de los modelos puede derivar de artefactos del conjunto de datos y no de la patología. A la espera de una prueba cuantitativa (por ejemplo, ablación del fondo), las exactitudes destacadas se leen con prudencia como una cota superior del rendimiento real en campo.

5 Discusión

Nuestros resultados respaldan una conclusión de dos caras. Por un lado, una CNN pequeña entrenada desde cero en una laptop *supera*—de forma significativa y reproducible— a las líneas base de aprendizaje por transferencia de red base congelada para este problema de tres clases, usando 7–34× menos parámetros. Esto




Figura 4: Matrices de confusión de prueba por modelo (texto de celda: conteos; color: tasa normalizada por fila).




Figura 5: Diagramas de fiabilidad (calibración). La diagonal punteada es la calibración perfecta; las barras muestran la exactitud dentro de cada compartimento de confianza.

debe leerse con cuidado: congelamos las redes base preentrenadas y entrenamos sólo un cabezal nuevo, la receta estándar de transferencia de bajo cómputo, de modo que la comparación es específicamente *entrenamiento de extremo a extremo desde cero frente a transferencia de características congeladas bajo un presupuesto de cómputo igual y modesto*. Hay también una asimetría que conviene declarar con claridad: como sus redes base están congeladas, las líneas base actualizan sólo 1,539–3,843 parámetros de cabezal durante el entrenamiento, mientras que la CNN desde cero optimiza todos sus 328,587 pesos. Por lo tanto, nuestra ventaja de “menos parámetros” se refiere al tamaño *total* del modelo—lo que debe almacenarse y ejecutarse en inferencia—no al número de pesos actualizados durante el entrenamiento. Un ajuste fino completo de las redes base muy probablemente elevaría su exactitud y podría reducir o revertir la brecha, pero también es sustancialmente más costoso y ávido de datos—precisamente el costo que nos propusimos evitar. El mensaje práctico se mantiene: para una tarea de diagnóstico estrecha y bien definida en hardware accesible, un modelo compacto a medida no es un compromiso sino una opción fuerte y mucho más barata. Por otro lado, el análisis con Grad-CAM es un resultado de advertencia que ninguna exactitud adicional sobre PlantVillage puede resolver: como los fondos del conjunto de datos son informativos, los altos puntajes dentro del conjunto no garantizan robustez en campo.

Limitaciones. El estudio está deliberadamente acotado. Las imágenes de PlantVillage son capturas de laboratorio con fondos limpios; las imágenes de campo contienen desorden, iluminación variable y condiciones concurrentes, y esperamos que todos los modelos se degraden con ellas. La tarea de papa de tres clases es comparativamente fácil, lo que comprime las diferencias entre arquitecturas. Congelamos las redes base de transferencia en lugar de ajustarlas por completo, cambiando un poco de exactitud por velocidad y por una comparación justa de bajo cómputo. No desplegamos en un dispositivo móvil, aunque los conteos de parámetros sugieren factibilidad.

Trabajo futuro. Los siguientes pasos naturales son la evaluación con imágenes de papa recolectadas en campo, la eliminación o segmentación explícita del fondo para forzar al modelo a centrarse en la hoja, y la evaluación en dispositivo de la latencia y la energía. La canalización reproducible publicada aquí está diseñada para facilitar esas extensiones.

6 Conclusión

Presentamos una comparación reproducible y estadísticamente cuidadosa de una CNN entrenada desde cero frente a líneas base de aprendizaje por transferencia de red base congelada para la clasificación de

enfermedades en hojas de papa con hardware de consumo. El modelo compacto a medida—más de un orden de magnitud más pequeño que ResNet-18 (34× menos parámetros)—supera significativamente a las líneas base por transferencia congelada bajo un presupuesto de cómputo igualmente bajo, y Grad-CAM revela una dependencia compartida del fondo del conjunto de datos que matiza todas las exactitudes reportadas. El trabajo aboga por un modelado de enfermedades vegetales honesto, interpretable y accesible en hardware, por encima de la persecución de tablas de clasificación.

Contribuciones de autoría

N.P. concibió y diseñó el estudio, implementó la canalización de datos, los modelos, el código de entrenamiento y evaluación, ejecutó los experimentos y los análisis estadísticos, produjo las figuras y redactó y revisó el manuscrito. Al tratarse de un trabajo de autor único, todas las contribuciones son atribuibles a N.P.

Disponibilidad de los datos

El conjunto PlantVillage está disponible públicamente [14]. El script de descarga y el subconjunto exacto de papa utilizado se describen en el repositorio de código; aquí no se redistribuyen datos de imagen.

Disponibilidad del código

Todo el código, las configuraciones, las dependencias fijadas y los scripts para reproducir cada número y figura de este manuscrito están disponibles en <https://github.com/nielspac177/papa-vision>.

Intereses en competencia

El autor declara no tener intereses en competencia.

Referencias

- [1] Food and Agriculture Organization of the United Nations. International year of the potato 2008: New light on a hidden treasure. *FAO, Rome*, 2009.
- [2] William Fry. Phytophthora infestans: the plant (and R gene) destroyer. *Molecular Plant Pathology*, 9(3):385–402, 2008.
- [3] Sharada P Mohanty, David P Hughes, and Marcel Salathé. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7:1419, 2016.
- [4] Konstantinos P Ferentinis. Deep learning models for plant disease detection and diagnosis. *Computers and Electronics in Agriculture*, 145:311–318, 2018.
- [5] Thomas G Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923, 1998.
- [6] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, pages 1321–1330. PMLR, 2017.
- [7] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.
- [8] Mehmet Alican Noyan. Uncovering bias in the PlantVillage dataset. *arXiv preprint arXiv:2206.04374*, 2022.
- [9] Jayme Garcia Arnal Barbedo. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. *Computers and Electronics in Agriculture*, 153:46–53, 2018.
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

- [11] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. MobileNetV2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4510–4520, 2018.
- [12] Mingxing Tan and Quoc Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, pages 6105–6114. PMLR, 2019.
- [13] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C Berg, and Li Fei-Fei. ImageNet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [14] David P Hughes and Marcel Salathé. An open access repository of images on plant health to enable the development of mobile disease diagnostics. *arXiv preprint arXiv:1511.08060*, 2015.
- [15] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning (ICML)*, pages 448–456. PMLR, 2015.
- [16] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958, 2014.
- [17] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [18] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [19] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2818–2826, 2016.
- [20] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems (NeurIPS)*, 32, 2019.

Grad-CAM: where each model looks (per class)




Figura 6: Superposiciones de Grad-CAM para un ejemplo representativo por clase. Las regiones cálidas son las más influyentes para la clase predicha. La atención se derrama hacia los bordes de la hoja y el fondo, ilustrando una dependencia consistente con el sesgo de fondo de PlantVillage (cualitativo; no es una métrica cuantitativa de atribución).