



CNN ligeras para el diagnóstico de enfermedades en hoja de papa con hardware de consumo

Entrenamiento desde cero vs. aprendizaje por transferencia, con interpretabilidad Grad-CAM

Niels Pacheco

MIA-07 — Redes Neuronales y Aprendizaje Profundo (Sección C)

Proyecto Final · Junio de 2026

¿Por qué la papa? ¿Por qué ahora?

- La **papa** (*Solanum tuberosum*) se domesticó en los **Andes peruanos** hace ~7,000 años y es el **3.er cultivo alimentario** más importante del mundo.
- El **tizón tardío** (*Phytophthora infestans*) causó la hambruna irlandesa y puede **arrasar un campo en días**; el **tizón temprano** (*Alternaria solani*) también está muy extendido.
- El diagnóstico experto es **escaso en las comunidades rurales andinas** — justo donde se concentra el cultivo.
- El aprendizaje profundo podría **democratizar el diagnóstico desde una sola foto de hoja** — *si* corre en el hardware que los agricultores realmente tienen.

La pregunta de investigación

¿Qué tan cerca puede llegar una CNN pequeña entrenada *desde cero* en una laptop sin GPU al aprendizaje por transferencia preentrenado en ImageNet para clasificar enfermedades en hoja de papa?

Dos vacíos en la literatura que abordamos:

1. La mayoría de los sistemas asume **GPU + grandes redes preentrenadas**.
2. Las exactitudes destacadas rara vez vienen con **intervalos de confianza, calibración, o una verificación de que el modelo mire la enfermedad**.

Contribuciones

1. Una **CNN propia compacta** (0.33 M parámetros) entrenable de extremo a extremo en CPU/Apple Silicon, comparada de frente con transferencia (MobileNetV2, ResNet-18, EfficientNet-B0 congeladas).
2. Una **evaluación estadísticamente rigurosa**: múltiples semillas, **IC bootstrap al 95%** y **prueba pareada de McNemar** — no un único número.
3. Un **análisis de calibración** (ECE + diagramas de fiabilidad), rara vez reportado en este dominio.
4. Un estudio de **interpretabilidad Grad-CAM** que sondea el **sesgo de fondo** de PlantVillage.
5. Una **publicación de código abierto totalmente reproducible** (dependencias fijadas, semillas fijas, un comando).

Datos: PlantVillage (subconjunto de papa)

- **2,152 imágenes**, 3 clases: **sana / tizón temprano / tizón tardío**
- Fotos controladas en laboratorio, **clases desbalanceadas** (pocas sanas)
- **Partición estratificada fija 70/15/15 → 1506 / 323 / 323** imágenes
- *El mismo conjunto de prueba para cada modelo* — requisito para una prueba de significancia válida
-  Los fondos son muy uniformes — volveremos a esto al final

Datos: ejemplos por clase

PlantVillage potato leaf classes

Healthy



Early blight



Late blight



Imágenes representativas del conjunto de prueba reservado. Note los fondos uniformes: una propiedad que, como mostraremos, los modelos pueden explotar.

Cuatro modelos, una comparación justa

Modelo	Origen	Parámetros
CNN propia	desde cero	~0.33 M
MobileNetV2	ImageNet, congelada + cabezal nuevo	~2.2 M
ResNet-18	ImageNet, congelada + cabezal nuevo	~11 M
EfficientNet-B0	ImageNet, congelada + cabezal nuevo	~4 M

- Mismo preprocesamiento y normalización ImageNet para todos → **sólo cambian arquitectura/pesos**
- En transferencia: **red base congelada**, se entrena sólo un cabezal de clasificación nuevo

La CNN propia (desde cero)

- **4 bloques convolucionales:** cada bloque = $2 \times (\text{Conv } 3 \times 3 + \text{BatchNorm} + \text{ReLU}) + \text{max pooling}$
- Anchos de canal **24 → 48 → 96 → 96** (crecen y se estabilizan para mantenerla compacta)
- **Global average pooling** → dropout 0.3 → clasificador lineal
- **328,587 parámetros totales**, *todos entrenables* de extremo a extremo
- Entradas 128×128, normalización ImageNet — idéntica a las líneas base

Metodología — entrenamiento

- **AdamW** + planificación coseno de la tasa de aprendizaje
- Entropía cruzada **ponderada por clase** + **suavizado de etiquetas** (contra el desbalance)
- **Parada temprana** sobre el F1 macro de validación
- **3 semillas aleatorias** por modelo → reportamos media $\pm$ desviación estándar
- Entrenado por completo en **Apple Silicon (MPS)**, sin GPU

Metodología — evaluación y estadística

- **Exactitud y F1 macro** (robusto al desbalance), media $\pm$ DE sobre 3 semillas
- **IC bootstrap** no paramétrico al 95% por corrida (incertidumbre dentro del test)
- **Prueba pareada de McNemar** sobre el test compartido (binomial exacta si hay pocas discordancias)
- **Calibración:** error de calibración esperado (ECE) + diagramas de fiabilidad
- **Grad-CAM** para ver *dónde mira* cada modelo

/autoresearch: búsqueda autónoma de hiperparámetros

- **Búsqueda aleatoria** con semilla, 10 ensayos, seleccionando por F1 macro de **validación** (nunca el test)
- Espacio: tasa de aprendizaje, decaimiento de pesos, ancho, dropout, intensidad de aumentación
- La mejor configuración se integró en `configs/custom_cnn.yaml`
- Trayectoria completa registrada → `autoresearch.jsonl` + dashboard + bitácora


Mejor F1 macro de validación: **96.9%** (ensayo 9: lr 1e-3, wd 1e-5, ancho 24, dropout 0.3, aug 0.5)

Resultados — tabla principal

Modelo	Params	Exactitud (%)	F1 macro (%)	ECE
CNN propia (desde cero)	328,587	97.3 ± 2.3	96.7 ± 2.1	0.123
EfficientNet-B0	4,011,391	94.9 ± 0.5	91.7 ± 1.4	0.157
MobileNetV2	2,227,715	94.9 ± 0.8	91.6 ± 1.2	0.134
ResNet-18	11,178,051	91.7 ± 1.5	86.5 ± 2.1	0.171


Media ± DE sobre 3 semillas. La CNN propia es la **mejor en exactitud, F1 macro y calibración** — con 7–34× menos parámetros.

Resultados — la CNN desde cero *gana*



- F1 macro **96.7%** > mejor transferencia **91.7%** (EfficientNet-B0)
- **McNemar**: supera significativamente a **los tres** modelos por transferencia ($p = 0.017, 0.004, 7e-5$)
- Las características congeladas de ImageNet **no están adaptadas al dominio**





Curvas de entrenamiento



- Las redes base preentrenadas **convergen rápido**; la CNN desde cero converge más lento a un nivel similar
- Todos alcanzan una **meseta alta** dentro del presupuesto de entrenamiento

Estructura de confusión

Test-set confusion matrices (counts; colour = row-normalized)



- Los errores de la CNN propia son sobre todo **enfermedad**




enfermedad (operativamente benignos — ambos requieren acción)



- La transferencia confunde algo de **tizón tardío** → **sana** (10–12 de 150): falsos negativos peligrosos
- La CNN propia no sólo puntúa más alto, también **falla de forma más segura**

Calibración


Reliability diagrams (calibration)



- Todos los modelos están **moderadamente mal calibrados** (ECE 0.12–0.17)
- La **CNN propia es la mejor calibrada**; la mala calibración viene sobre todo de la confianza media
- Un sistema desplegado se beneficiaría del **escalado por temperatura** antes de confiar en las probabilidades



¿Dónde miran los modelos?



- Atienden a las lesiones **pero también a bordes de la hoja y al fondo**
- Consistente con el **sesgo de fondo** de PlantVillage (Noyan 2022; Barbedo 2018)
- $\Rightarrow$ La exactitud de laboratorio es una **cota superior** del desempeño en campo

Discusión

Lo que sí podemos afirmar

- Una CNN pequeña entrenada **desde cero en una laptop** *supera significativamente* a la transferencia de red base congelada — con 7–34x menos parámetros.
- Bajo un **presupuesto de cómputo igualmente bajo**, aprender características del dominio de extremo a extremo vence a reutilizar características congeladas de ImageNet.

Lo que no debemos afirmar

- Que la alta exactitud en PlantVillage $\Rightarrow$ listo para el campo. El **sesgo de fondo** lo socava.
- Que la transferencia sea "peor" en general — el **ajuste fino completo** probablemente cerraría la brecha.

Limitaciones y trabajo futuro

Limitaciones

- Imágenes de **laboratorio** con fondos limpios; en campo esperamos degradación en todos los modelos.
- Tarea de **3 clases** comparativamente fácil → comprime las diferencias entre arquitecturas.
- Redes base **congeladas** (no ajuste fino completo); calibración moderada; sin despliegue en dispositivo aún.

Trabajo futuro

- Evaluación con **imágenes de campo** · eliminación/segmentación de fondo · benchmarking de **latencia y energía en dispositivo**

Conclusiones y reproducibilidad

- La CNN compacta entrenada **desde cero supera significativamente** a la transferencia congelada aquí (presupuesto de bajo cómputo igual); el ajuste fino completo costaría más.
- **Grad-CAM** revela una dependencia compartida del fondo del conjunto — **honestidad** por encima de perseguir el ranking.
- Todo se reproduce con **un solo comando** (entorno `uv` fijado, semillas fijas, figuras y artículo auto-generados):

```
make setup && make data && make train-all && make eval && make figures && make paper
```

Repositorio: github.com/nielspac177/papa-vision — ¡Gracias! · nielspacheco1997@gmail.com