

CNN ligeras para el diagnóstico de enfermedades en hoja de papa con hardware de consumo

Entrenamiento desde cero frente a aprendizaje por transferencia, con interpretabilidad Grad-CAM

Niels Pacheco

MIA-07: Redes Neuronales y Aprendizaje Profundo (Sección C)

Proyecto Final · Junio de 2026

¿Por qué la papa? ¿Por qué ahora?

- La papa (*Solanum tuberosum*) se domesticó en los Andes peruanos hace unos 7,000 años y es el tercer cultivo alimentario más importante del mundo.
- El tizón tardío (*Phytophthora infestans*) causó la hambruna irlandesa y puede arrasarse un campo en pocos días; el tizón temprano (*Alternaria solani*) también está muy extendido.
- El diagnóstico experto es escaso en las comunidades rurales andinas, justo donde se concentra el cultivo.
- El aprendizaje profundo podría democratizar el diagnóstico a partir de una sola foto de hoja, siempre que corra en el hardware que los agricultores realmente tienen.

La pregunta de investigación

¿Qué tan cerca puede llegar una CNN pequeña entrenada *desde cero* en una laptop sin GPU al aprendizaje por transferencia preentrenado en ImageNet para clasificar enfermedades en hoja de papa?

Dos vacíos en la literatura que abordamos:

1. La mayoría de los sistemas asume GPU y grandes redes preentrenadas.
2. Las exactitudes reportadas rara vez vienen con intervalos de confianza, calibración, o una verificación de que el modelo mire la enfermedad.

Contribuciones

1. Una CNN propia compacta (0.33 M parámetros) entrenable de extremo a extremo en CPU o Apple Silicon, comparada con tres modelos de transferencia (MobileNetV2, ResNet-18 y EfficientNet-B0 con red base congelada).
2. Una evaluación con varias semillas, intervalos de confianza por bootstrap al 95% y prueba pareada de McNemar, en lugar de un único número.
3. Un análisis de calibración (ECE y diagramas de fiabilidad), poco frecuente en este dominio.
4. Un estudio de interpretabilidad con Grad-CAM que examina el sesgo de fondo de PlantVillage.
5. Una publicación de código abierto reproducible: dependencias fijadas, semillas fijas, un comando.

Datos: PlantVillage (subconjunto de papa)

- 2,152 imágenes, 3 clases: sana, tizón temprano y tizón tardío
- Fotos controladas en laboratorio, con clases desbalanceadas (pocas sanas)
- Partición estratificada fija 70/15/15, que da 1506 / 323 / 323 imágenes
- El mismo conjunto de prueba para todos los modelos, requisito para una prueba de significancia válida
- Los fondos son muy uniformes, algo que retomamos al final

Datos: ejemplos por clase

PlantVillage potato leaf classes

Healthy



Early blight



Late blight



Imágenes representativas del conjunto de prueba reservado. Los fondos uniformes son una propiedad que, como mostramos, los modelos pueden explotar.

Cuatro modelos, una comparación justa

Modelo	Origen	Parámetros
CNN propia	desde cero	~0.33 M
MobileNetV2	ImageNet, congelada + cabezal nuevo	~2.2 M
ResNet-18	ImageNet, congelada + cabezal nuevo	~11 M
EfficientNet-B0	ImageNet, congelada + cabezal nuevo	~4 M

- Mismo preprocesamiento y normalización ImageNet para todos, así sólo cambian la arquitectura y los pesos
- En transferencia: red base congelada y se entrena sólo un cabezal de clasificación nuevo

La CNN propia (desde cero)

- 4 bloques convolucionales: cada bloque es $2 \times (\text{Conv } 3 \times 3 + \text{BatchNorm} + \text{ReLU})$ seguido de max pooling
- Anchos de canal 24, 48, 96, 96 (crecen y luego se estabilizan para mantenerla compacta)
- Global average pooling, dropout 0.3 y un clasificador lineal
- 328,587 parámetros totales, todos entrenables de extremo a extremo
- Entradas de 128×128 y normalización ImageNet, igual que las líneas base

Metodología: entrenamiento

- AdamW con planificación coseno de la tasa de aprendizaje
- Entropía cruzada ponderada por clase y suavizado de etiquetas, para contrarrestar el desbalance
- Parada temprana sobre el F1 macro de validación
- 3 semillas aleatorias por modelo; reportamos media y desviación estándar
- Hiperparámetros elegidos por búsqueda sobre el conjunto de validación (el de prueba nunca se consulta)
- Entrenado por completo en Apple Silicon (MPS), sin GPU

Metodología: evaluación y estadística


- Exactitud y F1 macro (robusto al desbalance), como media y desviación estándar sobre 3 semillas
- Intervalos de confianza por bootstrap no paramétrico al 95% por corrida
- Prueba pareada de McNemar sobre el conjunto de prueba compartido (binomial exacta cuando hay pocas discordancias)
- Calibración con ECE y diagramas de fiabilidad
- Grad-CAM para ver dónde mira cada modelo

Resultados: tabla principal

Modelo	Params	Exactitud (%)	F1 macro (%)	ECE
CNN propia (desde cero)	328,587	97.3 ± 2.3	96.7 ± 2.1	0.123
EfficientNet-B0	4,011,391	94.9 ± 0.5	91.7 ± 1.4	0.157
MobileNetV2	2,227,715	94.9 ± 0.8	91.6 ± 1.2	0.134
ResNet-18	11,178,051	91.7 ± 1.5	86.5 ± 2.1	0.171


Media y desviación estándar sobre 3 semillas. La CNN propia es la mejor en exactitud, F1 macro y calibración, con 7 a 34 veces menos parámetros.

Resultados: la CNN desde cero rinde mejor



- F1 macro de 96.7%, frente al 91.7% de la mejor transferencia (EfficientNet-B0)
- McNemar: supera de forma significativa a los tres modelos de transferencia ($p = 0.017, 0.004, 7e-5$)
- Las características congeladas de ImageNet no están adaptadas al dominio





Curvas de entrenamiento



- Las redes base preentrenadas convergen rápido; la CNN desde cero converge más lento hasta un nivel similar
- Todos alcanzan una meseta alta dentro del presupuesto de entrenamiento

Estructura de confusión


Test-set confusion matrices (counts; colour = row-normalized)



- Los errores de la CNN propia son casi todos confusiones entre las dos enfermedades, algo operativamente benigno porque ambas requieren acción
- La transferencia, en cambio, clasifica algo de tizón tardío como sana (10 a 12 de 150): falsos negativos peligrosos
- La CNN propia no sólo puntúa más alto, también falla de forma más segura


Calibración

Reliability diagrams (calibration)



- Todos los modelos están moderadamente mal calibrados (ECE entre 0.12 y 0.17)
- La CNN propia es la mejor calibrada; la mala calibración viene sobre todo de la confianza media
- Un sistema desplegado se beneficiaría del escalado por temperatura antes de confiar en las probabilidades

¿Dónde miran los modelos?



- Atienden a las lesiones, pero también a los bordes de la hoja y al fondo
- Es consistente con el sesgo de fondo de PlantVillage (Noyan 2022; Barbedo 2018)
- Por tanto, la exactitud de laboratorio es una cota superior del desempeño en campo

Discusión

Lo que sí podemos afirmar

- Una CNN pequeña entrenada desde cero en una laptop supera de forma significativa a la transferencia de red base congelada, con 7 a 34 veces menos parámetros.
- Bajo un presupuesto de cómputo igualmente bajo, aprender características del dominio de extremo a extremo vence a reutilizar características congeladas de ImageNet.

Lo que no debemos afirmar

- Que una alta exactitud en PlantVillage signifique que está listo para el campo. El sesgo de fondo lo impide.
- Que la transferencia sea peor en general: el ajuste fino completo probablemente cerraría la brecha.

Limitaciones y trabajo futuro

Limitaciones

- Imágenes de laboratorio con fondos limpios; en campo esperamos que todos los modelos se degraden.
- Tarea de 3 clases comparativamente fácil, lo que comprime las diferencias entre arquitecturas.
- Redes base congeladas (no ajuste fino completo), calibración moderada y sin despliegue en dispositivo todavía.

Trabajo futuro

- Evaluación con imágenes de campo, eliminación o segmentación del fondo, y medición de latencia y energía en dispositivo.

Conclusiones y reproducibilidad

- La CNN compacta entrenada desde cero supera de forma significativa a la transferencia congelada en este problema, bajo un presupuesto de bajo cómputo igual; el ajuste fino completo costaría más.
- Grad-CAM revela una dependencia compartida del fondo del conjunto, que matiza todas las exactitudes reportadas.
- Todo se reproduce con un solo comando (entorno `uv` fijado, semillas fijas, figuras y artículo auto-generados):

```
make setup && make data && make train-all && make eval && make figures && make paper
```

Repositorio: github.com/nielspac177/papa-vision · ¡Gracias! · nielspacheco1997@gmail.com